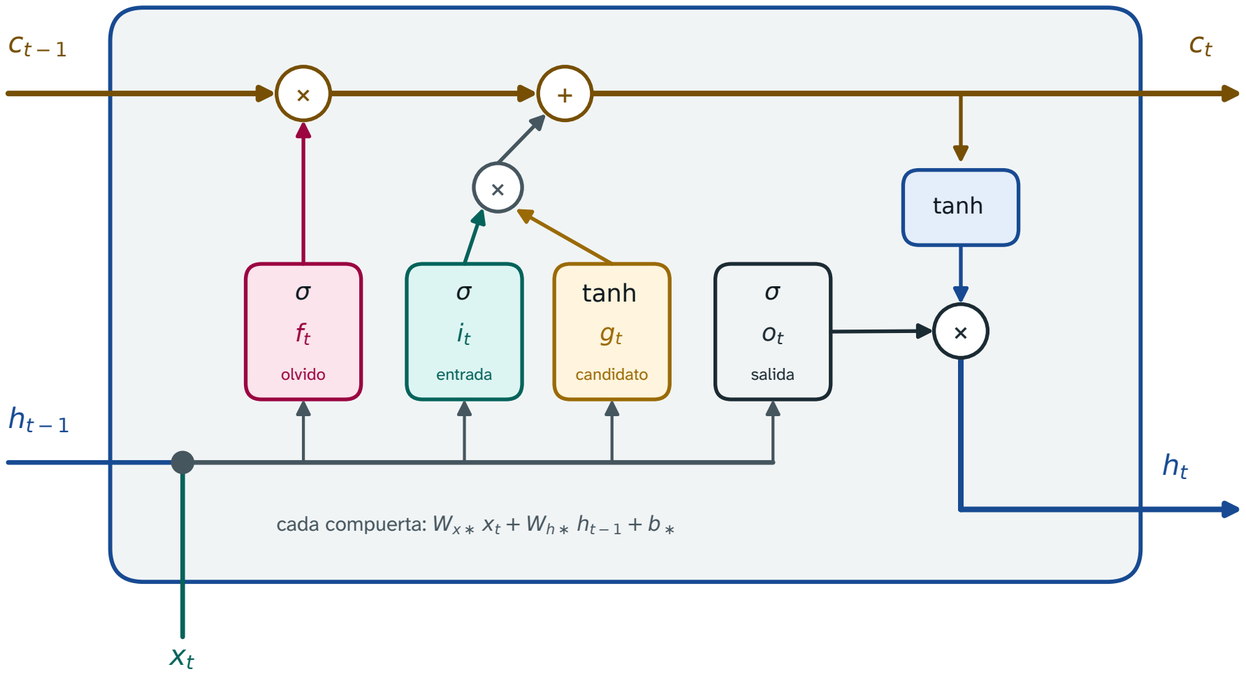
Red LSTM: la celda por dentro y la arquitectura de RedLSTM

La celda guarda dos estados: la memoria c_t (línea superior, camino aditivo) y el estado oculto h_t (lo que ve la capa siguiente)

A. Una celda LSTM en el paso t



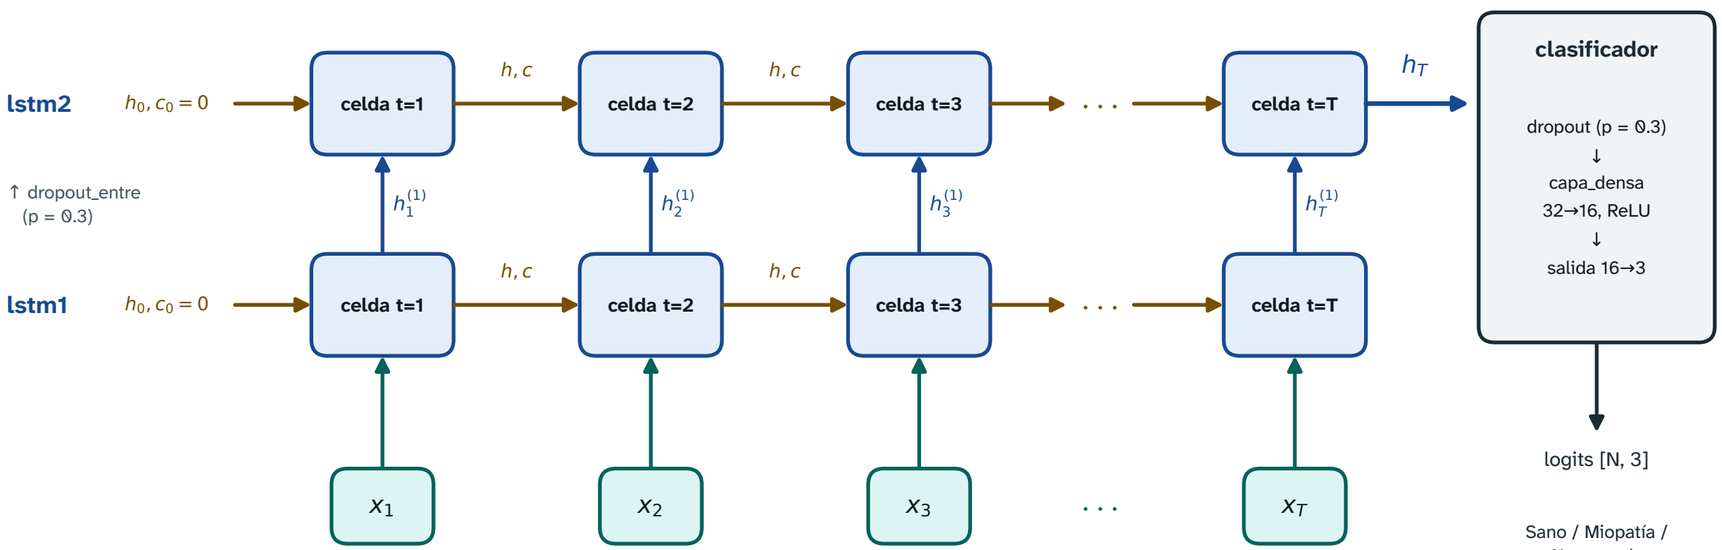
Ecuaciones (secciones 3.4 y 3.7)

$f_t = \sigma(W_{xf}\,x_t + W_{hf}\,h_{t-1} + b_f)$	compuerta de olvido: cuánto conservar
$i_t = \sigma(W_{xi}\,x_t + W_{hi}\,h_{t-1} + b_i)$	compuerta de entrada: cuánto escribir
$g_t = \tanh(W_{xg}\,x_t + W_{hg}\,h_{t-1} + b_g)$	contenido candidato
$o_t = \sigma(W_{xo}\,x_t + W_{ho}\,h_{t-1} + b_o)$	compuerta de salida: cuánto mostrar
$c_t = f_t \odot c_{t-1} + i_t \odot g_t$	actualización aditiva de la memoria
$h_t = o_t \odot \tanh(c_t)$	estado oculto

Gradiente por la memoria: $\partial c_t / \partial c_{t-1} = \mathrm{diag}(f_t)$; con $f_t \approx 1$ no se desvanece.

σ = sigmoide (valores en $(0, 1)$), $\odot$ = producto elemento a elemento, $\times$ y $+$ en los nodos ídem.

B. RedLSTM desenrollada: dos capas apiladas (lstm1 → lstm2) y clasificador



x: $[N, 32, 5]$ → salida de lstm1 (toda la secuencia, con dropout_entre): $[N, 32, 32]$ → lstm2

C. Parámetros (H = 32)

tensor	forma	parám.
`lstm1.weight_ih_l0`	[128, 5]	640
`lstm1.weight_hh_l0`	[128, 32]	4 096
`lstm1.bias_ih_l0 / hh`	2 × [128]	256
`lstm2.weight_ih_l0`	[128, 32]	4 096
`lstm2.weight_hh_l0`	[128, 32]	4 096
`lstm2.bias_ih_l0 / hh`	2 × [128]	256

lstm1: $4H(D + H + 2) = 4 \cdot 32 \cdot 39 = 4\,992$

lstm2: $4 \cdot 32 \cdot (32 + 32 + 2) = 8\,448$

$4H = 128$ filas = bloques apilados en el orden de PyTorch:

i	f	g	o

b_f inicial = 1