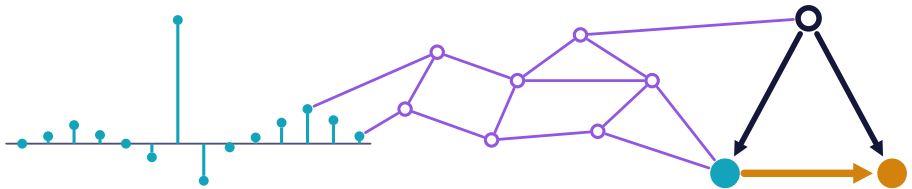
# Componentes principales

## Menos variables sin perder lo que importa

**P. E. Caicedo-Rodríguez**
Centro de Estudios en Biomédica y Biotecnología
2 de septiembre de 2026



# La idea



# Variables correlacionadas repiten información

- Los 13 parámetros de marcha no son independientes
  - velocidad, cadencia y longitud de paso se mueven juntas
- PCA busca nuevas variables, **no correlacionadas**, que resuman la tabla
- Cada componente es una combinación lineal de las variables originales

# Primero, estandarizar

Con unidades distintas (m/s, pasos/min, %), la variable de mayor escala domina:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

- Con datos estandarizados, PCA descompone la **matriz de correlación**

# Direcciones de máxima varianza

Si **R** es la matriz de correlación,

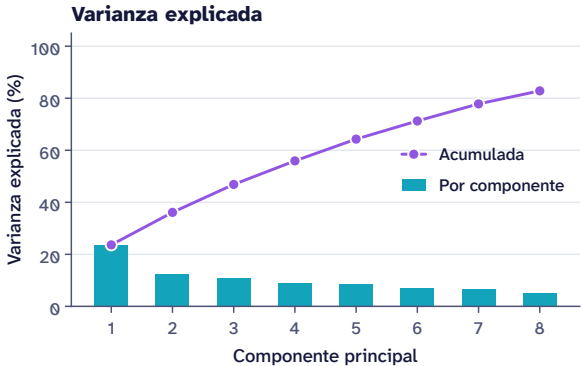
$$\mathbf{R}\,\mathbf{v}_k = \lambda_k\,\mathbf{v}_k, \qquad \lambda_1 \geq \lambda_2 \geq \ldots$$

- $\mathbf{v}_k$ son las **cargas:** cuánto pesa cada variable en la componente $k$
- $\lambda_k / \sum_j \lambda_j$ es la **proporción de varianza** que explica

# En la práctica

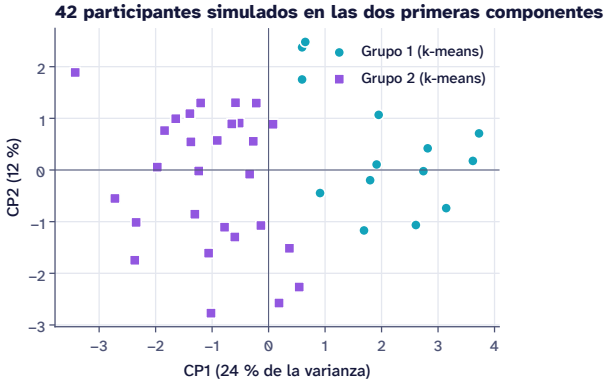


# ¿Cuántas componentes?




Datos simulados: la primera componente explica cerca de la cuarta parte de la varianza.

# Dos componentes, 42 participantes




Los grupos de k-means son estructura, no diagnóstico.

# En scikit-learn

```
from sklearn.decomposition import PCA
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

modelo = make_pipeline(StandardScaler(), PCA(n_components=2))
cp = modelo.fit_transform(medias)       # una fila por persona
modelo[-1].explained_variance_ratio_    # varianza por componente
```

# Lo que PCA no hace

- No sabe cuál variable importa para el **desenlace**: solo mira la varianza
- No crea información: resume la que ya está en la tabla
- Las componentes pueden ser difíciles de interpretar: se leen por sus cargas

# Para esta semana

**Laboratorio 2**

PCA y k-means sobre los parámetros de marcha simulados, y comparación de los grupos con el desenlace.